

LORIS ANTONIOLLI

FRENCH INDUSTRY

Rendu final

Cursus concerné : Data Analyst

sep25_continu_da



Table des matières

Introduction	3
1. Présentation et exploration des jeux de données	4
1.1 net_salary_per_town_categories.csv	4
Description & aperçu du jeu de données	4
Exploration supplémentaire du jeu de donnée	7
1.2 base_etablissement_par_tranche_effectif.csv	7
Description & Analyse du jeu de données	7
Processing & data cleaning	8
1.3 name_geographic information.csv	9
Description & Analyse du jeu de données	9
Processing & data cleaning	11
1.4 Population.csv	12
Description & Analyse du jeu de données	12
Processing & data cleaning	13
2. Visualisations	16
2.1 Overview des valeurs manquantes du jeu de données “name_geographic information”.	16
2.2 Répartition des communes par régions et départements	17
2.3 Répartition nationale des entreprises par Catégories INSEE	18
2.4 Effectifs par tranches d’âge	19
2.5 Analyse des distributions salariales par catégories	20
3. Conception et organisation du dashboard	21
3.1 Contexte démographique	22
3.2 Structure économique et disparités salariales	24
3.3 Dynamique territoriale : population et niveaux de salaire	28
3.4 Rôle du tissu économique dans les dynamiques territoriales	31
3.5 Synthèse	33
4. Conclusion	34
5. Bilan et perspective	35

Introduction

Le projet French Industry repose sur l'analyse de données publiques fournies par l'INSEE, organisme chargé de produire les statistiques économiques, sociales et démographiques en France. Il s'appuie sur quatre jeux de données portant sur les salaires, les entreprises, la population et les caractéristiques géographiques des communes.

En France, les écarts de niveau de vie ne s'expliquent pas uniquement par des facteurs individuels comme le métier ou le niveau de qualification. Le territoire joue également un rôle déterminant, en influençant les dynamiques économiques, l'accès à l'emploi et les niveaux de salaire.

Dans ce contexte, notre projet vise à analyser les relations entre population, activité économique et salaires à l'échelle des territoires, afin de mieux comprendre les mécanismes qui structurent les dynamiques territoriales.

La problématique retenue est la suivante :

Quels facteurs économiques et territoriaux influencent la répartition de la population en France ?

Pour y répondre, une première phase a consisté à préparer et analyser les jeux de données à l'aide de Python, afin d'en garantir la qualité et la cohérence.

Une seconde phase a permis de développer un tableau de bord interactif sur Power BI, visant à proposer une lecture claire et structurée des données.

Ce projet s'inscrit dans une démarche de visualisation de données, avec pour objectif de rendre compréhensibles des relations complexes issues de jeux de données volumineux, tout en proposant une analyse accessible à un public non spécialisé.

N° Col	Nom de la colonne	Description
1	CODGEO	ID géographique de la ville
2	LIBGEO	Nom de la ville
3	SNHM14	salaire net moyen
4	SNHMC14	salaire net moyen par heure pour les cadres
5	SNHMP14	salaire net moyen par heure pour un cadre moyen
6	SNHME14	salaire net moyen par heure pour l'employé
7	SNHMO14	salaire net moyen par heure pour le travailleur
8	SNHMF14	salaire net moyen pour les femmes
9	SNHMF14	salaire net moyen par heure pour les cadres féminins
10	SNHMF14	salaire net moyen par heure pour les cadres moyens féminins
11	SNHMF14	salaire net moyen par heure pour une employée
12	SNHMF14	salaire net moyen par heure pour une travailleuse
13	SNHMH14	salaire net moyen pour un homme
14	SNHMH14	salaire net moyen par heure pour un cadre masculin
15	SNHMH14	salaire net moyen par heure pour les cadres moyens masculins
16	SNHMH14	salaire net moyen par heure pour un employé masculin
17	SNHMH14	salaire net moyen par heure pour un travailleur masculin
18	SNHM1814	salaire net moyen par heure pour les 18-25 ans
19	SNHM2614	salaire net moyen par heure pour les 26-50 ans
20	SNHM5014	salaire net moyen par heure pour les >50 ans
21	SNHMF1814	salaire net moyen par heure pour les femmes âgées de 18 à 25 ans
22	SNHMF2614	salaire net moyen par heure pour les femmes âgées de 26 à 50 ans
23	SNHMF5014	salaire net moyen par heure pour les femmes de plus de 50 ans
24	SNHMH1814	salaire net moyen par heure pour les hommes âgés de 18 à 25 ans
25	SNHMH2614	salaire net moyen par heure pour les hommes âgés de 26 à 50 ans
26	SNHMH5014	salaire net moyen par heure pour les hommes de plus de 50 ans

Ces données vont nous permettre d'analyser les inégalités salariales à l'échelle communale, en croisant des dimensions individuelles (âge, sexe, catégorie d'emploi) et territoriales.

Processing & data cleaning

Nous commençons avec une première phase de contrôle afin d'évaluer la qualité globale du jeu de données :

- Nous n'avons identifié aucune valeur manquante.
- Les types des colonnes sont corrects :
 - Variables catégorielles (CODGEO et LIBGEO) au format string
 - Variables salariales au format numérique (float)

Par la suite, dans un souci de lisibilité pour nos futures analyses, les colonnes ont été renommées afin de remplacer les codes INSEE par des intitulés logiques pour nous à l'exception de CODGEO voir ci dessous :

CODGEO	nom_commune	sal_moyen	sal_cadres	sal_cadres_moyens	sal_employes	sal_ouvriers	sal_femmes	sal_cadres_femmes	sal_cadres_moyens_femmes
--------	-------------	-----------	------------	-------------------	--------------	--------------	------------	-------------------	--------------------------

Des vérifications de cohérence ont ensuite été menées entre certaines variables :

- comparaison des niveaux de salaires entre cadre et employé,
- comparaison des salaires selon le sexe,
- cohérence des valeurs entre tranches d'âge.

=> Aucune incohérence manifeste n'a été détectée (voir ci-dessous).

Nombre de valeurs négatives dans le dataset : 0

Nombres de salaires cadres supérieurs aux salaires employés : 0

Nombres de salaires cadres femmes supérieurs aux salaires employés femmes : 0

Nombres de salaires cadres hommes supérieurs aux salaires employés hommes : 0

Nombres de salaires employés supérieurs aux salaires ouvriers : 4505

Nombres de salaires age 18-25 supérieurs aux salaires age 26-50 : 9

Une valeur maximale atypique a toutefois été observée pour une variable salariale (voir ci-dessous). Celle-ci n'a pas été traitée à ce stade, car elle peut s'expliquer par des spécificités locales (structure de l'emploi, faible effectif, concentration de cadres).

	sal_age18_25	sal_age26_50	sal_age50_plus
count	5136.0	5136.0	5136.0
mean	10.0	13.0	16.0
std	1.0	2.0	4.0
min	8.0	10.0	10.0
25%	9.0	12.0	14.0
50%	10.0	13.0	15.0
75%	10.0	14.0	17.0
max	61.0	38.0	57.0

À ce stade, le jeu de données est exploitable pour les analyses exploratoires prévues, sous réserve des limites liées à l'agrégation des données et à l'échelle communale.

Exploration supplémentaire du jeu de données

Le jeu de données salarial couvre 5 136 communes, soit une partie seulement des communes françaises. Cette couverture partielle s'explique vraisemblablement par des contraintes liées à la disponibilité et à la fiabilité des données salariales.

Des vérifications exploratoires complémentaires ont été réalisées afin de mieux comprendre le périmètre du jeu de données salarial. Ces tests suggèrent que les communes présentes correspondent majoritairement à celles disposant d'un niveau minimal d'activité économique, ce qui confirme que la couverture du fichier est liée à des critères de disponibilité et de fiabilité des données salariales, et non à une perte d'information lors du traitement.

1.2 base_etablissement_par_tranche_effectif.csv

Description & Analyse du jeu de données

Ce jeu de données recense le nombre d'établissements par commune, ventilés selon des tranches d'effectifs de salariés.

On a de nouveau la colonne CODGEO qui correspond au code INSEE des communes sauf que sur ce dataframe nous avons 36681 lignes et 14 colonnes.

Les colonnes détaillant les tranches d'effectifs sont nombreuses, allant des établissements sans salarié jusqu'aux entreprises de plus de 500 salariés.

	CODGEO	LIBGEO	REG	DEP	E14TST	E14TS0ND	E14TS1	E14TS6	E14TS10	E14TS20	E14TS50	E14TS100	E14TS200	E14TS500
0	01001	L'Abergement-Clémenciat	82	01	25	22	1	2	0	0	0	0	0	0
1	01002	L'Abergement-de-Varey	82	01	10	9	1	0	0	0	0	0	0	0
2	01004	Ambérieu-en-Bugey	82	01	996	577	272	63	46	24	9	3	2	0
3	01005	Ambérieux-en-Dombes	82	01	99	73	20	3	1	2	0	0	0	0
4	01006	Ambléon	82	01	4	4	0	0	0	0	0	0	0	0

N° Col	Nom de la colonne	Description
1	CODGEO	ID géographique de la commune
2	LIBGEO	nom de la commune
3	REG	numéro de région
4	DEP	numéro de département
5	E14TST	nombre total d'entreprises dans la ville
6	E14TS0ND	nombre d'entreprises de taille inconnue ou nulle dans la ville
7	E14TS1	nombre d'entreprises de 1 à 5 employés dans la ville
8	E14TS6	nombre d'entreprises de 6 à 9 employés dans la ville
9	E14TS10	nombre d'entreprises de 10 à 19 employés dans la ville
10	E14TS20	nombre d'entreprises de 20 à 49 employés dans la ville
11	E14TS50	nombre d'entreprises de 50 à 99 employés dans la ville
12	E14TS100	nombre d'entreprises de 100 à 199 employés dans la ville
13	E14TS200	nombre d'entreprises de 200 à 499 employés dans la ville
14	E14TS500	nombre d'entreprises de plus de 500 employés dans la ville

Processing & data cleaning

Nous commençons avec une première phase de contrôle pour vérifier ce jeu de données , et on note :

Une première phase de contrôle a permis de vérifier que le jeu de données :

- Qu'il ne contient pas de valeurs manquantes,
- Qu'il ne présente pas de doublons,
- Qu'il possède des types de variables cohérents avec leur usage à l'exception de la colonne **REG** (que nous avons convertie en object)
- Que la colonne CODGEO ne contient que des lignes avec 5 caractères.

Bien que techniquement exploitable en l'état, nous pensons que la granularité très élevée de ce jeu de données complexifie inutilement la compréhension mais surtout sa future utilisation lors de nos prochaines analyses.

Nous décidons alors de regrouper en catégories plus synthétiques les colonnes de cette manière :

- Micro-Entreprise : 0 à 9 salariés (E14TS0ND + E14TS1 + E14TS6)
- Petite Entreprise : 10 à 49 salariés (E14TS10 + E14TS20)
- Moyenne Entreprise : 50 à 199 salariés (E14TS50 + E14TS100)
- Grande Entreprise : + de 200 salariés (E14TS200 + E14TS500)

On obtient un data frame plus lisible et plus simple pour comparer les communes entre elles. Les colonnes détaillées sont par la suite supprimées, nous obtenons donc un data frame synthétique et clair, plus en adéquation pour l'utilisation que nous en ferons dans nos prochaines analyses.

	CODGEO	LIBGEO	REG	DEP	Micro_E	Petites_E	Moyennes_E	Grandes_E	Total_entreprises
0	01001	L'Abergement-Clémenciat	82	01	25	0	0	0	25
1	01002	L'Abergement-de-Varey	82	01	10	0	0	0	10
2	01004	Ambérieu-en-Bugey	82	01	912	70	12	2	996
3	01005	Ambérieux-en-Dombes	82	01	96	3	0	0	99
4	01006	Ambléon	82	01	4	0	0	0	4

(36681, 9)

1.3 name_geographic information.csv

Description & Analyse du jeu de données

Le jeu de données regroupe des informations géographiques et administratives relatives aux communes françaises.

Il contient 36 840 lignes et 14 colonnes, chaque ligne correspondant à une commune identifiée par son code INSEE.

Ce jeu de données constitue le référentiel géographique central du projet. Il permet de contextualiser l'ensemble des autres sources de données en apportant :

- les rattachements administratifs (région, département),
- les identifiants officiels,
- les coordonnées géographiques nécessaires aux analyses spatiales et aux visualisations cartographiques.

Aperçu du jeu de données :

	EU_circo	code_région	nom_région	chef.lieu_région	numéro_département	nom_département	préfecture	numéro_circonscription	nom_commune	codes_pos
0	Sud-Est	82	Rhône-Alpes	Lyon	01	Ain	Bourg-en-Bresse	1	Attignat	0
1	Sud-Est	82	Rhône-Alpes	Lyon	01	Ain	Bourg-en-Bresse	1	Beaupont	0
2	Sud-Est	82	Rhône-Alpes	Lyon	01	Ain	Bourg-en-Bresse	1	Bény	0
3	Sud-Est	82	Rhône-Alpes	Lyon	01	Ain	Bourg-en-Bresse	1	Béreyziat	0
4	Sud-Est	82	Rhône-Alpes	Lyon	01	Ain	Bourg-en-Bresse	1	Bohas-Meyriat-Rignat	0

N° Col	Nom de la colonne	Description
1	EU_circo	Grandes zones géographiques
2	code_région	Code de la région
3	nom_région	Nom de la région
4	chef.lieu_région	Ville principale de la région
5	numéro_département	Numéro de département de la région
6	nom_département	Nom du département
7	préfecture	Ville où se situe la préfecture : l'administration centrale
8	numéro_circonscription	Fait référence à l'identifiant d'une circonscription électorale, c'est-à-dire une subdivision territoriale utilisée pour organiser les élections législatives.
9	nom_commune	Nom officiel d'une commune
10	codes_postaux	Code postal de la zone géographique pour la localisation
11	code_insee	Code INSEE qui est un identifiant numérique attribué par l'INSEE. Il sert à identifier de manière unique des entités comme les communes, les entreprises, ou les personnes dans les bases de données administratives et statistiques.
12	latitude	Indique la latitude : Coordonnées géographiques permettant de positionner précisément un lieu sur une carte
13	longitude	Indique la longitude: Coordonnées géographiques permettant de positionner précisément un lieu sur une carte.
14	éloignement	Indicateur du niveau d'isolement géographique relatif des communes.

Processing & data cleaning

Une première phase d'exploration a permis d'identifier plusieurs points nécessitant un traitement spécifique afin de garantir la cohérence et l'exploitabilité du jeu de données.

- Dans un premier temps, certaines colonnes représentant des identifiants administratifs (**code_région**, **numéro_circonscription**, **code_insee**) étaient initialement typées en valeurs numériques. Nous les avons donc converties en chaînes de caractères afin de garantir leur utilisation comme identifiants catégoriels.
- La colonne **code_insee** a également été renommée en **CODGEO**, afin d'harmoniser la clé de jointure avec les autres jeux de données du projet, qui utilisent tous le code communal comme identifiant principal.
- Par ailleurs, l'exploration a révélé que certains codes INSEE comportaient initialement seulement quatre caractères, le zéro de gauche étant absent. Un formatage a donc été appliqué afin de garantir que l'ensemble des codes communaux soit représenté sur cinq caractères, avec conservation des zéros à gauche. Cette étape est indispensable pour assurer la fiabilité des jointures entre les différents jeux de données.

<u>code_insee</u>		<u>CODGEO</u>
1024		01024
1029		01029
1038		01038
1040		01040
1245		01245

L'exploration du jeu de données a mis en évidence la présence de plusieurs lignes partageant un même code INSEE. Cette situation s'explique par la présence de caractéristiques administratives multiples pour certaines communes (par exemple circonscriptions différentes).

Dans le cadre du projet, l'unité d'observation retenue est la commune, identifiée de manière unique par son code INSEE.

À ce stade, aucune transformation n'a été appliquée sur ces lignes multiples. Ce choix vise à conserver l'intégralité de l'information disponible, nous verrons pendant les analyses approfondies si un reformatage du jeu de données est nécessaire.

Les **colonnes latitude, longitude et éloignement** présentaient un nombre non négligeable de valeurs manquantes. La probabilité de les utiliser est assez faible, donc afin d'alléger le jeu de données principal et d'éviter l'introduction de données incomplètes dans les jointures, ces colonnes ont été retirées du jeu de données de travail.

Toutefois, par précaution, une copie du jeu de données original a été conservée, permettant de réintégrer ces informations ultérieurement si nécessaire dans nos futures analyses.

À l'issue de ces traitements, le jeu de données constitue un référentiel géographique homogène, cohérent et aligné avec les autres sources du projet.

Il est désormais adapté aux opérations de fusion avec les jeux de données économiques, salariales et démographiques.

1.4 Population.csv

Description & Analyse du jeu de données

Ce DataFrame décrit la structure démographique des communes françaises selon trois dimensions principales : l'âge, le sexe et le mode de cohabitation.

Chaque ligne correspond à une combinaison unique, d'une commune, d'une tranche d'âge, d'un sexe, d'un mode de cohabitation et indique le nombre de personnes associé à cette combinaison.

Le jeu de données est le plus volumineux, avec plus de 8,5 millions de lignes, ce qui s'explique par la granularité très fine des informations démographiques. Ce qui implique sûrement la nécessité de transformations et d'agrégations avant toute exploitation avec les autres datasets de notre projet.

Aperçu du jeu de données:

	NIVGEO	CODGEO	LIBGEO	MOCO	AGEQ80_17	SEXE	NB
0	COM	1001	L'Abergement-Clémenciat	11	0	1	15
1	COM	1001	L'Abergement-Clémenciat	11	0	2	15
2	COM	1001	L'Abergement-Clémenciat	11	5	1	20
3	COM	1001	L'Abergement-Clémenciat	11	5	2	20
4	COM	1001	L'Abergement-Clémenciat	11	10	1	20

N° Col	Nom de la colonne	Description
1	NIVGEO	Niveau géographique d'agrégation (toujours COM = commune).
2	CODGEO	Code géographique INSEE de la commune.
3	LIBGEO	Nom de la commune.
4	MOCO	Mode de cohabitation (11 deux parents, 12 un parent, 21 couple sans enfant, 22 couple avec enfants, 23 seul avec enfants, 31 étranger au foyer, 32 seul).
5	AGEQ80_17	Tranche d'âge (0-4, 5-9, 10-14 ...).
6	SEXE	Sexe : 1 Homme, 2 Femme.
7	NB	Effectif de population pour la combinaison (âge × sexe × commune × cohabitation).

Processing & data cleaning

Une première phase de contrôle a permis de vérifier la qualité du jeu de données :

- Aucune valeur manquante n'a été détectée
- Aucun doublon n'a été identifié, y compris sur la clé logique composée de la commune, de l'âge, du sexe et du mode de cohabitation.
- Les types de données sont cohérents :
 - Les identifiants géographiques sont correctement typés en chaînes de caractères,
 - Les variables catégorielles (âge, sexe, mode de cohabitation) sont encodées sous forme d'entiers
 - La variable NB, représentant les effectifs, est de type entier.

Pour ce jeu de données, nous avons dû comme pour le précédent formater la colonne CODGEO, dont certaines lignes comportent à nouveau seulement 4 caractères, avec le 0 initial absent.

CODGEO		CODGEO
1001		01001
1001		01001
1001		01001
1001		01001
1001		01001



Pour des raisons de compréhension et de clarté nous avons apporté des modifications, en créant des colonnes dérivées pour les colonnes : **AGEQ80_17**, **MOCO** et **SEXE**.

COLONNE ORIGINE – « AGEQ80_17 »	COLONNE AJOUTEE – « TRANCHE_AGE »
0	0-4 ans
5	5-9 ans
10	10-14 ans
15	15-19 ans
20	20-24 ans
25	25-29 ans
30	30-34 ans
35	35-39 ans
40	40-44 ans
45	45-49 ans
50	50-54 ans
55	55-59 ans
60	60-64 ans
65	65-69 ans
70	70-74 ans
75	75-79 ans
80	80 ans et plus

COLONNE ORIGINE – « MOCO »	COLONNE AJOUTEE – « MOCO_LABEL »
11	« enfants avec deux parents »
12	« enfants avec un parent »
21	« adultes en couple sans enfant »
22	« adultes en couple avec enfants »
23	« adulte seul avec enfants »
31	« personne étrangère à la famille au foyer »
32	« personne vivant seule »

COLONNE ORIGINE – « SEXE »	COLONNE AJOUTEE – « SEXE_LABEL »
1	Homme
2	Femme

Aperçu du nouveau jeu de données :


	NIVGEO	CODGEO	LIBGEO	MOCO	AGEQ80_17	SEXE	Nb_personnes_concernees	TRANCHE_AGE	MOCO_LABEL	SEXE_LABEL
0	COM	01001	L'Abergement-Clémenciat	11	0	1	15	0-4 ans	enfants avec deux parents	Homme
1	COM	01001	L'Abergement-Clémenciat	11	0	2	15	0-4 ans	enfants avec deux parents	Femme
2	COM	01001	L'Abergement-Clémenciat	11	5	1	20	5-9 ans	enfants avec deux parents	Homme
3	COM	01001	L'Abergement-Clémenciat	11	5	2	20	5-9 ans	enfants avec deux parents	Femme
4	COM	01001	L'Abergement-Clémenciat	11	10	1	20	10-14 ans	enfants avec deux parents	Homme
5	COM	01001	L'Abergement-Clémenciat	11	10	2	45	10-14 ans	enfants avec deux parents	Femme
6	COM	01001	L'Abergement-Clémenciat	11	15	1	30	15-19 ans	enfants avec deux parents	Homme
7	COM	01001	L'Abergement-Clémenciat	11	15	2	15	15-19 ans	enfants avec deux parents	Femme
8	COM	01001	L'Abergement-Clémenciat	11	20	1	10	20-24 ans	enfants avec deux parents	Homme
9	COM	01001	L'Abergement-Clémenciat	11	20	2	0	20-24 ans	enfants avec deux parents	Femme

Le jeu de données est donc fiable et les colonnes sont devenues plus claires à la compréhension de celui-ci.

2. Visualisations


Cette section présente des visualisations descriptives destinées à illustrer la structure des jeux de données et à en vérifier la cohérence générale. Elles permettent notamment d'observer les distributions des variables clés et de détecter ou de confirmer d'éventuelles anomalies.

2.1 Overview des valeurs manquantes du jeu de données “name_geographic_information”.




Ce graphique met en évidence que la majorité des variables sont complètes dans ce jeu de données, et nous confirme que les colonnes latitude, longitude et éloignement concentrent l'essentiel des valeurs manquantes.

2.2 Répartition des communes par régions et départements



Ce graphique permet de visualiser la structure territoriale du dataset et de vérifier la cohérence de la couverture géographique, en mettant en évidence des différences importantes entre les régions en termes de nombre de communes. Cette représentation confirme que le jeu de données couvre l'ensemble du territoire français.


2.3 Répartition nationale des entreprises par Catégories INSEE



Ce graphique présente la répartition nationale des entreprises par catégorie de taille, selon la classification INSEE, à partir de notre modification du jeu de données `base_etablissement_par_tranche_effectif`.


Il met en évidence la structure globale du tissu économique français, caractérisée par une écrasante majorité de micro-entreprises, tandis que les petites, moyennes et grandes entreprises représentent une part nettement plus réduite de l'ensemble. Cette visualisation permet de comprendre la composition générale des entreprises présentes dans le jeu de données..

2.4 Effectifs par tranches d'âge



Ce graphique représente les effectifs de population par tranche d'âge à partir du jeu de données population.csv. Chaque point correspond à une observation issue d'une commune pour une tranche d'âge donnée. Ce graphique confirme que la distribution des effectifs par tranche d'âge est logique, structurée et exploitable.

2.5 Analyse des distributions salariales par catégories



Ce graphique présente, sous forme de boxplots, les distributions des principales variables salariales du jeu de données `net_salary_per_town_categories`. Chaque boxplot correspond à une catégorie salariale et permet de visualiser la médiane, la dispersion et la présence éventuelle de valeurs atypiques. Cela nous permet d'observer les ordres de grandeur et de vérifier la cohérence globale des données de notre jeu de données.

3. Conception et organisation du dashboard

Notre dashboard a été conçu selon une logique progressive. L'objectif est de partir d'une lecture descriptive des données via des pages contextuelles, pour aller vers une analyse plus approfondie des relations entre population, activité économique et niveaux de salaire.

Notre structure s'organise en plusieurs pages complémentaires :


- Une première page de contexte dédiée au contexte démographique,
- Une seconde centrée sur la structure économique et les niveaux de salaire,
- Deux pages d'analyse mettant en relation ces dimensions,
- Une page de synthèse des dynamiques territoriales.

Cette organisation permet de construire un raisonnement progressif et cohérent, facilitant l'interprétation des données.

3.1 Contexte démographique

Cette première page du dashboard vise à poser le cadre de l'analyse en étudiant la structure et la répartition de la population sur le territoire français.


→ L'objectif est d'identifier les caractéristiques démographiques susceptibles d'influencer les dynamiques économiques observées par la suite.



La carte de la population met en évidence une forte concentration territoriale, notamment dans les grandes zones urbaines et en Île-de-France.

Cette répartition inégale constitue un premier élément : les territoires ne disposent pas du même poids démographique, ce qui influence directement leur potentiel économique.


Cette lecture est complétée par l'analyse de la **répartition de la population selon le type de ville** :




Le premier graphique nous montre que les petites et moyennes villes concentrent une part importante des habitants. Toutefois, cette concentration ne se traduit pas nécessairement par un niveau équivalent d'activité économique.

Le second graphique sur le nombre de types de ville vient compléter et expliquer la répartition de la population en nous montrant la concentration des différents types de ville en France. On observe que les petites villes sont très largement majoritaires ce qui contribue à concentrer une part importante de la population.

C'est pourquoi dans notre graphique suivant "la population active par type de ville" nous permet d'aller plus loin dans l'analyse, en mettant en évidence que les métropoles présentent une part plus élevée de population en âge de travailler, ce qui traduit un potentiel productif supérieur.



L'association des ces graphiques nous permet déjà de mettre en évidence que la valeur économique d'un territoire ne dépend pas uniquement de sa population totale mais surtout de la part de population active qu'il concentre.



Enfin, l'analyse de la structure des ménages permet d'apporter un éclairage complémentaire sur les modes de vie. Bien qu'elle ne constitue pas un facteur direct de création de valeur, elle influence les dynamiques locales, notamment en matière de consommation et d'attractivité.

Dans l'ensemble, cette première lecture montre que les dynamiques démographiques sont hétérogènes sur le territoire Français et constituent un facteur structurant des inégalités territoriales.


3.2 Structure économique et disparités salariales

Cette deuxième page de contexte vise à analyser les niveaux de salaire en France et à comprendre dans quelle mesure ils sont influencés par la structure économique des territoires.


Salaire horaire national pondéré...	Salaire/Horaire Médian...	Écart Salaire/Horaire (Max-Min)
13,71 €	13,00 €	33,10 €

Les KPIs globaux permettent de situer le niveau général des rémunérations en France. L'écart observé entre le salaire médian et les valeurs extrêmes met en évidence une dispersion importante des salaires, traduisant l'existence d'inégalités importantes sur le territoire.

Salaire horaire national pondéré (pop. active) par Département



La représentation cartographique met en évidence des disparités territoriales marquées. Certains territoires, notamment les plus urbanisés et économiquement dynamiques, concentrent des niveaux de salaire plus élevés, tandis que d'autres présentent des niveaux plus faibles.



L'analyse par catégorie socio-professionnelle permet d'affiner la lecture en mettant en évidence des écarts importants selon le type d'emploi. Les cadres présentent des niveaux de rémunération significativement plus élevés que les ouvriers ou employés.


La comparaison entre hommes et femmes ajoute une information importante en mettant en évidence des écarts persistants entre les deux sexes, notamment dans les catégories les plus rémunératrices.

Ces résultats montrent que les inégalités salariales s'expliquent également par la structure du marché du travail, en lien avec la répartition des qualifications et des types d'emploi.

Sur la deuxième partie de cette page nous nous pencherons sur l'aspect du tissu économique du pays.




Les KPIs relatifs aux entreprises permettent de donner une vue d'ensemble du tissu économique français.



La répartition des entreprises selon le type de ville montre que l'activité économique est présente sur l'ensemble du territoire, mais qu'elle n'est pas homogène et varie selon le type de villes.

→ Cela nous permet de faire le lien avec l'analyse démographique précédente, en montrant que la localisation de l'activité économique suit en partie celle de la population, tout en restant différenciée selon les types de territoires.



Ce graphique met en évidence une caractéristique majeure du tissu économique français : une très forte domination des micro-entreprises, tandis que les grandes entreprises restent très minoritaires.

C'est un élément qui pourrait jouer un rôle important et impacter directement sur les niveaux de salaire, les grandes entreprises étant généralement associées à des niveaux de rémunération plus élevés et à des emplois plus qualifiés.

Dans l'ensemble, cette page contextuelle met en évidence que les disparités salariales ne s'expliquent pas uniquement par des facteurs individuels, mais qu'elles sont étroitement liées aux caractéristiques économiques des territoires.


La structure du tissu entrepreneurial, ainsi que la répartition des activités économiques, apparaissent comme des facteurs déterminants dans la formation des niveaux de salaire.

Cela permet ainsi de faire la transition vers l'analyse suivante, qui vise à étudier plus directement la relation entre population, activité économique et niveaux de rémunération à l'échelle territoriale.

3.3 Dynamique territoriale : population et niveaux de salaire

Cette page vise à analyser la relation entre la concentration de la population active et les niveaux de salaire, en comparant les dynamiques observées entre l'Île-de-France et la Province.

L'objectif est de comprendre dans quelle mesure la taille du marché du travail influence les rémunérations, et si cette relation varie selon les territoires.



Ce graphique met en évidence une relation positive entre la population active et le niveau de salaire : les territoires disposant d'un marché du travail plus important tendent à présenter des niveaux de rémunération plus élevés.

La distinction entre l'Île-de-France et la Province permet d'affiner cette lecture. On observe que les territoires franciliens se situent globalement à des niveaux de salaire plus élevés pour des volumes de population comparables.

Cela met en évidence une différence de dynamique entre les deux variables :

La relation entre population active et salaire apparaît plus marquée en Île-de-France, traduisant une capacité plus forte à transformer la concentration de population en valeur économique.

À l'inverse, en Province, la relation est plus diffuse, suggérant que d'autres facteurs viennent influencer les niveaux de rémunération.




Afin de confirmer cette observation, les coefficients de corrélation ont été calculés pour chaque zone. Ils permettent de mesurer l'intensité du lien entre population active et niveau de salaire.

On retrouve bien les résultats observés sur le graphique précédent qui nous montrent que la corrélation est plus élevée en Île-de-France qu'en Province.

Cela confirme notre hypothèse que la relation entre taille du marché du travail et niveau de rémunération est plus forte en Île-de-France, où la concentration de population se traduit plus efficacement en création de valeur économique.

Mais si la corrélation permet de mesurer l'intensité du lien entre population active et salaire, elle ne renseigne pas sur la manière dont les salaires sont répartis au sein des territoires.

Pour cela, nous allons analyser la distribution des salaires afin de mieux comprendre les différences observées entre l'Île-de-France et la Province.



On observe que les salaires sont globalement plus élevés en Île-de-France, avec une médiane supérieure. De plus, la dispersion y est plus importante, comme le montre l'étendue plus large du boxplot.

Cela traduit une plus grande hétérogénéité économique, avec la présence à la fois de salaires très élevés et de salaires plus faibles.

À l'inverse, en Province, les salaires apparaissent plus concentrés autour de la médiane, ce qui suggère une structure économique plus homogène mais avec des niveaux de rémunération globalement plus faibles.

Cette page met en évidence une relation positive entre la concentration de la population active et les niveaux de salaire, avec des dynamiques plus marquées en Île-de-France qu'en Province. Elle montre ainsi que les facteurs démographiques jouent un rôle important dans les écarts de rémunération et contribuent à expliquer la répartition de la population sur le territoire.


Toutefois, ces résultats suggèrent que la taille du marché du travail ne suffit pas à elle seule à expliquer ces disparités.

La suite de l'analyse vise donc à intégrer la dimension économique afin de mieux comprendre ces mécanismes.

3.4 Rôle du tissu économique dans les dynamiques territoriales


Cette page vise à analyser le rôle du tissu économique dans les dynamiques territoriales, en étudiant la relation entre la densité d'entreprises et les niveaux de salaire.

L'objectif est de déterminer dans quelle mesure la structure économique permet d'expliquer les écarts observés précédemment entre les territoires.



Ce graphique met en évidence une relation positive entre le nombre d'entreprises et les niveaux de salaire. Les territoires les plus denses économiquement tendent à présenter des niveaux de rémunération plus élevés.

Cela s'explique par le fait qu'un tissu économique développé favorise la création d'emplois, la diversité des activités et la présence d'entreprises à plus forte valeur ajoutée.



L'analyse de la taille des entreprises met en évidence une forte dominance des micro-entreprises, tandis que les grandes entreprises restent minoritaires.

Cette structure influence directement les niveaux de salaire, les grandes entreprises étant généralement associées à des emplois plus qualifiés et mieux rémunérés.

Globalement, ces résultats nous indiquent que la densité et la structure du tissu économique jouent un rôle clé dans les dynamiques territoriales. Les territoires disposant d'un tissu économique plus développé bénéficient de meilleures opportunités d'emploi et de niveaux de salaire plus élevés.

Cette analyse confirme que les facteurs économiques, en complément des dynamiques démographiques, participent fortement à la structuration des niveaux de salaire et à la répartition de la population sur le territoire.

Elle permet ainsi de répondre à la problématique en montrant que les inégalités territoriales résultent d'une combinaison de facteurs démographiques et économiques.

3.5 Synthèse

L'ensemble des analyses réalisées met en évidence que la répartition de la population en France s'explique par la combinaison de plusieurs facteurs démographiques et économiques.

Les territoires caractérisés par une forte concentration de population active et une densité économique élevée présentent globalement des niveaux de salaire plus importants, ce qui renforce leur attractivité.

À l'inverse, les territoires moins dynamiques économiquement se distinguent par des niveaux de rémunération plus faibles et une structure démographique différente.

Ces résultats montrent que les dynamiques territoriales reposent sur un équilibre entre population, activité économique et niveau de vie, et qu'aucun de ces facteurs ne peut être analysé de manière isolée.

Ainsi, la répartition de la population en France apparaît comme le résultat d'interactions complexes entre ces différentes dimensions.

4. Conclusion

Ce projet a permis de mener une analyse complète des dynamiques territoriales en France, en combinant données démographiques, économiques et salariales.

La première phase d'exploration et de préparation des données effectuée à l'aide de Python, a permis de vérifier leur qualité et leur cohérence, tout en mettant en évidence certaines caractéristiques structurantes, telles que la dominance des micro-entreprises, les disparités salariales ou encore la concentration de l'activité économique dans les grandes métropoles.

Dans un second temps, le développement d'un dashboard interactif sur Power BI a permis d'approfondir l'analyse et de mettre en évidence des relations entre les différentes variables étudiées.

Les résultats montrent que les territoires caractérisés par une forte concentration de population active et un tissu économique dense présentent globalement des niveaux de salaire plus élevés, ce qui renforce leur attractivité. À l'inverse, les territoires moins dynamiques économiquement se distinguent par des niveaux de rémunération plus faibles.

La comparaison entre l'Île-de-France et la Province illustre particulièrement ces écarts, avec des niveaux de salaire plus élevés et une dynamique économique plus marquée en Île-de-France.

Ainsi, ce projet a permis d'apporter des éléments de réponse à la problématique en montrant que la répartition de la population en France est étroitement liée à l'interaction entre facteurs économiques et territoriaux.

5. Bilan et perspective

L'une des principales difficultés rencontrées au cours du projet a été le choix initial d'une problématique trop ambitieuse au regard des données disponibles et du temps imparti. Cette complexité s'est révélée lorsque nous avons commencé la partie visualisation des données, et par conséquent, cela a nécessité une réorientation progressive de l'analyse afin de proposer une approche plus réaliste et exploitable.

La phase de datavisualisation a également représenté une difficulté importante. Elle s'est révélée plus complexe que prévu, notamment en raison de la nécessité d'adapter la problématique au fur et à mesure de l'avancement du projet.

En effet, la construction du tableau de bord a permis de mieux comprendre les possibilités mais aussi les limites des données disponibles. Certains axes d'analyse envisagés initialement se sont révélés difficilement exploitables, ce qui a nécessité des ajustements dans la manière d'aborder le problème et donc du temps supplémentaire

Cette phase, bien que plus longue que prévue, nous a permis au final d'aboutir à une analyse plus cohérente et mieux alignée avec les données.

Dans l'ensemble, je dirais que les objectifs du projet ont été atteints. Le dashboard développé permet de mettre en évidence des relations claires entre population, activité économique et niveaux de salaire.

L'analyse a notamment permis d'identifier plusieurs facteurs structurants, tels que la concentration de la population active, la densité économique ou encore la structure du tissu entrepreneurial.

Le projet a permis de mieux comprendre les dynamiques territoriales en passant d'une simple description des données à une analyse des relations entre les différentes variables. Néanmoins, ces résultats doivent être interprétés avec prudence, car ils mettent en évidence des liens entre variables sans pour autant prouver un lien de causalité direct.

Lors de nos analyses, plusieurs pistes d'amélioration nous sont parvenues afin d'enrichir l'analyse :

L'intégration de données supplémentaires, notamment sur les secteurs d'activité des entreprises, permettrait d'affiner la compréhension des niveaux de salaire. En effet, certains secteurs étant plus rémunérateurs que d'autres, leur répartition territoriale pourrait expliquer une partie des écarts observés.

L'ajout de données sur la répartition des catégories socio-professionnelles (cadres, employés, ouvriers) constituerait également une amélioration pertinente. En effet, la structure des emplois au sein d'un territoire influence directement les niveaux de salaire. Une plus forte proportion de cadres peut par exemple expliquer des niveaux de rémunération plus élevés, indépendamment du nombre d'entreprises ou de la population.